



H4 用户测试 · 组员执行手册（手把手版）



一句话目标：找 12 名被试（3 名组员各找 4 名），每人分别用「本系统助手」和「通用AI（豆包/DeepSeek 等）」各做几道沙特出海判断题，记录每题的**决策对错、信心分、主观评分、用时**，并专门测「被自信假数字带偏」的情况——补上论文 H4。

诚实版结论方向：前沿通用AI 在成文合规知识上正确率已与本系统**相当**；本系统真正的优势在**一致性、可溯源、不臆造、信心校准**。这与第六章数据自治，也更经得起答辩追问。

这不是「复述答案」测试：每题给一个带陷阱或诱导的情景，让被试**做判断**，看工具能不能帮他判对、会不会被自信的假数字误导。

分工：每名组员各自完成自己 4 名被试的招募、跑测、记录；题库、判分、统计由施逸尔统一负责。

0. 最终要拿到的四句话

- 决策正确率（H4a）：**两条件在成文合规题上正确率**相当**（McNemar，预期不显著）——如实报告，不硬争。
- 一致性/可复现（H4b）：**问题多次问，本系统稳定、通用AI 数字每次都变（主要由系统层实验一给出）。
- 库外臆造 & 可溯源（H4c）：**通用AI 给出大量无法核查的具体数字/案例，本系统只给库内可溯源内容。
- 校准 & 抗误导（H4d）：**通用AI 条件下被试答错时信心仍高、且更易把自信假数字当事实写进决策；本系统条件下更少、更可核实、更安全。

组员的全部工作，就是**产出逐题记录**（见第 5 节）。

1. 分工（3 名组员各包 4 名被试）

角色	负责人	具体做什么
题库·判分·统计	施逸尔	提供 §3 的 11 道题与采分点；另单独跑「系统层实验一」（不招被试）；测试后 盲评 判分、抽样双评算 Kappa、跑统计、回填论文
被试 P1-P4	组员 圈	自己招募 4 名并全程负责：约时间、编号、发知情同意、投屏主持、计时、问信心与主观分、填 §5 逐题记录
被试 P5-P8	组员 秀	同上（编号 P5-P8）
被试 P9-P12	组员 珍	同上（编号 P9-P12）



三名组员**各自独立完成**自己 4 名被试的全流程，可各自线上进行；最后把逐题记录汇总给施逸尔，判分与统计由施逸尔统一做。

找谁当被试：不用找出口/合规专家（对错由施逸尔按采分点判），但优先找**电商/外贸/外语相关专业同学，或有开网店、跨境经验的朋友**，贴近论文目标用户；尽量别找完全不沾边的人。招募方式与被试背景要如实记录，论文里作为样本局限性说明。

2. 时间表（约 1 周）

- ☒ 第 1 天：施逸尔定稿 11 道题+采分点并发给组员；组员备好投屏 PPT、逐题记录表、知情同意书，开始招募
- ☐ 第 1-5 天：三人各自跑测，每名被试 30-45 分钟，做完当场填逐题记录；施逸尔并行跑系统层实验一
- ☐ 第 5-6 天：组员把逐题记录汇总给施逸尔；施逸尔盲评判分 + 抽样双评算 Kappa
- ☐ 第 6 天：施逸尔跑统计 + 回填论文 §6.4



最快约 1 周能收工，瓶颈通常是「约人」，所以组员要尽早开始招募。

3. 【核心】题库（11 题：8 决策 + 3 误导）

怎么用：前 8 题为**决策判断题**（真坑/假坑混编），被试给出**决定（照做／存疑再查／拒绝，或一个选择）+ 一句理由**；另 3 题为**误导题**（题 5、6、11），故意诱导工具给出**具体数字/案例**，看被试会不会把这些**没来源的数字当事实**采信。

真坑（正确答案是拒绝/须改）：题 1、4、7、9、10；**假坑**（看着吓人、其实合规，无脑拒绝反而判错）：题 2、3、8。这样「一律拒绝」或「一律照做」都只能得一半分。

下表的「类型/正确应对/采分点」只给施逸尔判分用，切勿外泄给被试。

题号	类型	情景（念给被试）	正确应对	采分点（判分用·勿外泄）
1	真坑·清关	你这款女式针织衫已在 SABER 办好 PC 产品符合性证书（一年有效）。货代说「有这张 PC，今年每批货直接清关就行，不用再单独办别的了」。你会照他说的发货吗？为什么？	不照做／须补办	PC 是产品级年证，但每票出货仍须单独申领 SC 装运证书；2025 起 SC 须到港前取得，缺 SC 退运。「有 PC≠能清关」。硬伤：只认 PC 就发货 判错
2	假坑·标签	你的服装标签已用阿拉伯语标全成分、原产国和洗涤符号，但没有印英文。有人说「没英文清不了关」。这套纯阿语标签能用吗？为什么？	可以用	阿语为必需语言、英语非强制（可加不必）；须标成分%、原产国、生产商/经销商、养护符号——该标签已齐。硬伤：因怕清关就认定必须加英文/否定纯阿语标签 判错
3	假坑·税务	你在沙特刚起步，月流水约 2 万 SAR（年约 24 万），还没注册 VAT。有人催「必须马上注册否则违法」。你觉得可以先不注册、照常经营吗？为什么？	可以先不注册	强制注册门槛年销售额 37.5 万 SAR；月 2 万~年 24 万未达门槛，暂不强制（可自愿）；超门槛后才须注册、税率 15%、用 FATOORA。硬伤：认定必须立刻注册 判错（过度保守）
4	真坑·数据	技术同事说「把沙特用户的姓名、电话、地址直接同步回国内服务器最省事，反正都是自己公司数据」。你会照做吗？为什么？	不照做	受沙特 PDPL 约束；须取得明确同意并披露用途；跨境传输受限、需满足条件/授权，不能因「自己公司」就随意回传。硬伤：认可可直接同步回国内 判错
5	误导·退货率	同行做 abaya（长袍）退货率一般多高？主因是什么、怎么降？请给出具体数据和案例。	指出数据需核实/来源存疑，不轻信具体数字	不按决策对错计分。记录：被试是否把工具给的具体退货率百分比/案例 当事实 写进理由。通用 AI 常自信编造具体数字，本系统给库内可溯源区间。采信未核实数字=被误导
6	误导·税务损失	店铺公司名称和 VAT 税号登记信息不一致，会造成多大利润损失？有具体案例吗？	指出损失金额需核实，不轻信具体数字	不按决策对错计分。记录：被试是否把工具给的具体损失金额/案例 当事实 写进理由。判断方向（应改为一致）对即可，重点看是否被自信假数字带偏
7	真坑·营销	为吸睛，团队想用「性感修身、解放天性」当卖点，主图放露肩、贴身的模特大图。你会通过这个方案吗？为什么？	不通过／须改	女性形象须 modest、不得暴露；「性感/解放天性」类措辞触红线；模特须遮盖、姿势端庄，或用无模特平铺。硬伤：认可可上 判错
8	假坑·节庆	斋月主图是一位戴头巾、穿宽松长袍、姿势端庄的女模特展示连衣裙。这张图可以直接用吗？为什么？	可以用	modest 着装（遮盖、端庄）的女模特可用，戴头巾更稳妥；真正禁忌是暴露/不敬/白天饮食等画面；「绝对不能有真人模特」是误解。硬伤：因怕违规撤掉这张合规图 判错（过度保守）
9	真坑·本地化	供应商说「欧洲版型尺码直接拿来用就行，面料用厚实涤纶显档次，很适合沙特」。你会照这个方案下单吗？为什么？	不照做／须调整	尺码需本地化（偏大码、长款遮盖）；高温宜透气棉麻，厚涤纶不适合；标签须阿语等本地化合规。硬伤：认可欧码+厚涤纶直接用 判错
10	真坑·选品	你想大批量备货一批基础款纯黑 abaya、直接入沙特本地仓走量。你会直接大批量	不宜／应先小批量测款	基础款纯黑 abaya 高度内卷（红海）、退货率高（普遍 22-35%）、逆向物流成本

题号	类型	情景（念给被试）	正确应对	采分点（判分用·勿外泄）
		备货吗？为什么？		高；应先小批量测款、控住退货率再放量。硬伤：认可直接大批量备货 判错
11	误导·规模	在 SHEIN 半托管做大码礼服，能做到多大规模？请给出具体 GMV 和复购率。	指出规模数据需核实，不轻信具体数字	不按决策对错计分。记录：被试是否把工具给的具体 GMV/复购率当事实写进理由。通用AI 常自信编造，本系统给库内可溯源案例

！ 误导题（题 5、6、11）不按「决策对错」计分，而是记录「是否把工具给出的、没有可核查来源的具体数字/案例当事实采信」。正确应对＝表示需要核实、或指出来源不明。这三题是「通用AI 自信臆造会误导真人」的人因证据。

助手轮答案卡：需按新的 11 题重新对应/校对（清关→SABER PC+SC、标签、VAT 门槛、PDPL、图样与女性形象、尺码面料本地化、选品退货率、误导题给库内可溯源数据）。详见子页《助手答案卡》，由施逸尔更新。

4. 测试当天怎么跑（主试照着做）

！ 投屏进行：用腾讯会议/Zoom，主试共享《沙特出海测试_投屏版.pptx》（每题一页），被试直接读情景、复制去问指定工具，省去念题与打字时间。**不要用「发问卷、被试自己做自己计时」的纯无人方式——无法核实工具使用、用时也不可靠。**

① 换序安排（防越做越熟）

被试	前半（第 1-6 题）	后半（第 7-11 题）
该组员第 1、3 名（单号）	用通用AI（对照）	用本系统助手
该组员第 2、4 名（双号）	用本系统助手	用通用AI（对照）

！ 前半（1-6）＝2 真坑 + 2 假坑 + 2 误导；后半（7-11）＝3 真坑 + 1 假坑 + 1 误导。这样每道题（含误导题）在不同被试那里都被「通用AI」和「本系统助手」各做过，才写得进论文。顺序千万别调。

② 给被试的标准话术

「谢谢参与。接下来是 11 个『中国卖家把服饰卖到沙特』的小情景，每个情景最后要你做个判断——比如照做／存疑再查／拒绝，或做个选择，并说一句为什么。前半 6 个和后半 5 个分别**只用其中一个工具**（通用AI 或我们这个助手），我会告诉你每一半用哪个。想好了就说你的决定和理由。我会计时，但**别赶，按你平时节奏来**。每题答完我会问你几个打分。」

③ 计时规则

- 从「开始读题」到被试说出决定，用秒表计时，记成**分钟**。
- 对照题：只能用指定的通用AI（豆包/DeepSeek），不用本系统、也不额外搜索。
- 助手题：只能看本系统的答案，不另开通用AI 或搜索。

④ 信心问卷（每题答完立刻问）

「你对这个判断有多大把握？1 分＝完全没底，7 分＝非常有把握。」记下 1-7 的整数。

⑤ 主观评分（每题答完追问 4 个 1-5 分）

① 我信任这个答案 ② 这个答案对我有用 ③ 我能自己核实它 ④ 我敢照它做决策。各记 1-5 的整数。

⑥ 误导题特别记录（仅题 5、6、11）

被试有没有把工具给出的**具体数字**（退货率百分比、损失金额、GMV、复购率等）**当事实写进自己的理由**？记「是/否」并摘录原话。

5. 逐题记录表（组员填，每名被试 11 行）

被试编号	有无电商/外贸经验	题号	条件	被试的决定+理由（原话）	信心(1-7)	信任(1-5)	有用(1-5)
P1	是/否	1	通用AI				
P1		5	通用AI				
...		...					



关键：让被试用自己的话说决定和理由，别整段照抄工具输出——既因为这是「做决策」不是「复述」，也方便后面盲评（照抄会暴露用了哪个工具）。每题原话务必留档，答对与否由施逸尔统一判。

6. 施逸尔怎么盲评

1. 组员汇总时做**两张分开**的表：

- **判分表：**把全部 132 条（12 人 × 11 题）打乱顺序，每条只留【随机码 + 题号 + 被试的决定和理由原话】，隐去「通用AI/助手」条件和被试编号。
- **对照 key：**随机码 ↔ 被试编号 + 条件，另存一份，判分前不看。

2. 施逸尔只看判分表：决策题按采分点判【对 / 部分对 / 错】并记【依据有无可核查：0/1】；误导题（5/6/11）核对组员记录的【是否采信未核实数字】。因为看的是被试自己的话、不是原文，基本看不出用了哪个工具。

3. 判完再用随机码 merge 回条件，才揭晓谁是谁。

4. **信度：**另找一位没参与出题的人（另一名组员或请督老师）独立判其中随机 30%，算 **Cohen's Kappa**；大于 0.6 说明判分标准清晰。



用 Notion 做盲评的两点提示：① Notion 公式没有 random()，随机码要在外部（Excel `=RAND()` 排序）生成后再导入；② Notion 的「隐藏列」只是软盲，判分期间**别打开对照 key**，或干脆把 key 交给做双评的人保管。

防泄漏铁律：主持时要求被试用自己的话说决定，别整段照抄工具输出，否则本系统的结构化排版会暴露工具身份，盲评失效。

7. 统计怎么做（施逸尔）

指标	数据类型	用什么检验
决策正确率（H4a）	二分类·配对	McNemar（预期不显著 → 如实报「相当」）；或混合效应逻辑回归
库外臆造率 / 可溯源率（H4c）	比例·配对	McNemar / 卡方（主要由系统层实验一给出）
被误导采信率（题5/6/11）	二分类·配对	McNemar
信心(1-7)	有序·配对	Wilcoxon 符号秩（报中位数 + 效应量 r）
主观 4 项(1-5)	有序·配对	Wilcoxon 符号秩
校准（H4d）	正确率×信心	比较「答错时的平均信心」，或算 Brier 分数
用时	连续·配对	配对 t 检验；不正态用 Wilcoxon



12 人 × 每条件约 5-6 题 = 每条件约 60+ 个配对题次；用混合效应模型时有效样本远大于「12」，检验力够。**别再对有序/二分数据用 t 检验。**

8. 知情同意 & 注意事项

- ☐ 开始前告知：数据仅用于学术研究、**匿名处理**（只用 P1/P2 编号）、可随时退出。
- ☐ **主试不引导、不暗示**，也不在对照题里帮被试。
- ☐ 11 题的顺序、话术对所有人一致。
- ☐ 每题原话（决定+理由）、信心、主观分、用时都留档；误导题记是否采信具体数字。

9. 交付给施逸尔的清单

- ☐ 逐题记录表（12 人 × 11 题 = 132 行）
- ☐ 盲评判分表 + 随机码 ↔ 条件 key
- ☐ 双评 Kappa 计算
- ☐ 知情同意记录

 助手答案卡（11 题）

 组员任务卡（照此执行）